

Laboration 2

Andrew Dean & Ekaterina Kershinskaia

2026-10-09

Sammanfattning

Den här labben handlar om att använda slumpalsgeneratorer för att simulera olika fördelningar för att få en bättre intuition för hur olika fördelningar beter sig. Vi vill också undersöka likformigheten av R:s inbyggd slumpalsgenerator.

Uppgift 1

Teoretiska uppgifter

Uppgift 1.1

Vi delar intervallet $[0, 1]$ i k lika stora delintervall.

Det första delintervallet ges alltså av $I_1 = [0, \frac{1}{k}]$.

Det sista delintervallet ges av $I_k = [1 - \frac{1}{k}, 1]$.

Uppgift 1.2

Längden hos varje delintervall ges av $l = \frac{1}{k}$.

Uppgift 1.3

Sannolikheten att ett slumptal genererad från $Likf[0, 1]$ hamnar i I_1 är $\frac{1}{k}$.

Sannolikheten att ett slumptal genererad från $Likf[0, 1]$ inte hamnar i I_1 är $1 - \frac{1}{k}$.

Sannolikheten att hamna i det första delintervallet ges av en **Bernoullifördelning** med parametern $p = \frac{1}{k}$.

Uppgift 1.4

Om vi genererar nu n slumptal från $Likf[0, 1]$, sannolikheten att j av dessa hamnar i det första delintervallet ges av en **binomialfördelning** $X_1 \sim B(n, \frac{1}{k})$ eftersom alla genererade slumptal är oberoende och har densamma sannolikhet att hamna i I_1 . Sannolikheten ges alltså av:

$$P(X_1 = j) = \binom{n}{j} \cdot \left(\frac{1}{k}\right)^j \cdot \left(1 - \frac{1}{k}\right)^{n-j}$$

Uppgift 1.5

Ja, $X_1, X_2, X_3, \dots, X_k$ har samma sannolikhetsfördelning som X_1 . Det här är för att sannolikheten att hamna i ett godtyckligt delintervall är fortfarande $\frac{1}{k}$, eftersom alla delintervall är lika stora.

$X_1, X_2, X_3, \dots, X_k$ är ej obereonde av varandra. Till exempel, om $X_1 = n$, då medför det att $X_j = 0$ för alla andra $j \neq 1$, eftersom det finns inga slumpetal kvar att hamna i ett annat delintervall än I_1 .

Uppgift 1.6

Vi sätter $Y_1 := \frac{X_1}{n}$, dvs. andelen av observationerna som hamnar i I_1 .

$$\mathbb{E}[X_1] = np = n \cdot \frac{1}{k} = \frac{n}{k}.$$

$$\text{Var}(X_1) = np(1-p) = \frac{n}{k}(1 - \frac{1}{k}).$$

$$\mathbb{E}[Y_1] = \mathbb{E}[\frac{X_1}{n}] = \frac{1}{n}\mathbb{E}[X_1] = \frac{1}{n} \cdot \frac{n}{k} = \frac{1}{k}.$$

$$\text{Var}(Y_1) = \text{Var}(X_1/n) = \frac{1}{n^2} \text{Var}(X_1) = \frac{1}{n^2} \cdot \frac{n}{k}(1 - \frac{1}{k}) = \frac{1}{nk}(1 - \frac{1}{k}).$$

$$D(Y_1) = \sqrt{\text{Var}(Y_1)} = \sqrt{\frac{1}{nk}(1 - \frac{1}{k})}.$$

Kodrelaterade uppgifter

```
set.seed(19981207)

K <- 10

calculate_attributes <- function(n) {
  E_X = n/K
  Var_X = (n/K)*(1 - 1/K)
  D_X = sqrt(Var_X)

  E_Y = E_X/n
  Var_Y = Var_X/(n^2)
  D_Y = sqrt(Var_Y)

  list(E_X = E_X, D_X = D_X, E_Y = E_Y, D_Y = D_Y)
}


antal_hist <- function(x, E_X, D_X) {
  hist(
    x,
    breaks = seq(from = 0, to = max(1, max(x)), length.out = K + 1), # Skapar 10 delintervall
    main = "Histogram",
    ylab = "Antal",
    xlab = "Värde",
    ylim = c(0, E_X + 4*D_X)
  )
  abline(a = E_X, b = 0, col = "grey")
  abline(a = E_X + 3*D_X, b = 0, col = "red")
  abline(a = E_X - 3*D_X, b = 0, col = "red")
}
```

```
andel_hist <- function(x, E_Y, D_Y, xlab="Värde") {
  p <- hist(x, breaks = seq(from = 0, to = max(1, max(x)), length.out = K + 1), plot = FALSE)
  p$counts <- p$counts / sum(p$counts)      # Konvertera antal till andelar
  plot(p,
        main = "Andelshistogram",
        ylab = "Andel",
        xlab = xlab,
        ylim = c(0, E_Y + 4*D_Y))
  axis(2)
  abline(a = E_Y, b = 0, col = "grey")
  abline(a = E_Y + 3*D_Y, b = 0, col = "red")
  abline(a = E_Y - 3*D_Y, b = 0, col = "red")
}
```

```
n <- 100


slumptal <- runif(n)
attributes = calculate_attributes(n)

antal_hist(slumptal, attributes$E_X, attributes$D_X)
```



Figur 1: Antalet observationer per delintervall (n=100)

```
andel_hist(slumptal, attributes$E_Y, attributes$D_Y)
```



Figur 2: Andelen observationer per delintervall ($n=100$)


```
n <- 1000  
  
slumptal <- runif(n)  
attributes = calculate_attributes(n)  
  
antal_hist(slumptal, attributes$E_X, attributes$D_X)
```

```
andel_hist(slumptal, attributes$E_Y, attributes$D_Y)
```


1. I Figur 2 ser vi andelen slumpmässigt genererade observationer som hamnar i varje delintervall. Det ser inte exakt ut som en likformig fördelning (som förväntas vara helt “platt”), särskilt i det första delintervallet, men det här är på grund av det lilla urvalet av bara $n = 100$ observationer.

Det är dock väl inom 3 standardavvikelser av det som förväntas av en likformig fördelning med så få observationer (visat av de röda linjer på histogrammet), och därför kan vi inte dra slutsatsen att observationerna inte kom från en sådan fördelning.

Se uppgifter 2 och 3 nedan för en djupare teoretisk förklaring.



Figur 3: Antalet observationer per delintervall (n=1000)



Figur 4: Andelen observationer per delintervall (n=1000)

2. För större n , som $n = 1000$ (se Figur 4), ser andelshistogrammet väldigt mycket "plattare" ut. Ännu större värden på n ger en ännu "plattare" fördelning. Det här är förväntat eftersom standardavvikelse $\sigma \propto \frac{1}{\sqrt{n}}$.
3. Vi förväntar oss att andelen i var och en av de 10 klasserna ska vara $1/10 = 0.1$.
I Figur 2, där $n = 100$, 3 standardavvikelser ges av:

$$3\sigma_{n=100} = 3\sqrt{\frac{1}{nk}(1 - \frac{1}{k})} = 3\sqrt{\frac{1}{100 \cdot 10}(1 - \frac{1}{10})} = 0.09.$$
Den största avvikelsen i Figur 2 är Y_1 , där felet är $|0.1 - 0.05| = 0.05$, som är märkbart mindre än $3\sigma = 0.09$.
I Figur 4, där $n = 1000$, 3 standardavvikelser ges av:

$$3\sigma_{n=1000} = 3\sqrt{\frac{1}{nk}(1 - \frac{1}{k})} = 3\sqrt{\frac{1}{1000 \cdot 10}(1 - \frac{1}{10})} \approx 0.028.$$
Den största avvikelsen i Figur 4 är Y_7 , där felet är ungefär $|0.1 - 0.09| = 0.01$, som också är betydligt mindre än $3\sigma = 0.028$.
4. Det finns inga delintervall (i fallet $n = 100$ eller $n = 1000$) där andelen observationer är fler än 3 standardavvikelser från det förväntade värdet. Alltså blir R:s slumpalsgenerator godkänd.

Uppgift 2

I denna uppgift undersöker vi exponential- och normalfördelade slumpstal genom simuleringar i R. Histogrammet jämförs med täthetsfunktionen för respektive fördelning, eftersom andelshistogrammet visar hur observationerna fördelar sig över de olika delintervall. För varje fördelning jämförs resultat från $n_1 = 100$ och $n_2 = 10000$ observationer.


```
set.seed(19981207)

prop_hist <- function(x, xlab = "Värde") {
  p <- hist(x, plot = FALSE)
  p$counts <- p$counts / sum(p$counts) # Konvertera antal till andelar
  plot(p,
        main = "Andelshistogram",
        ylab = "Andel",
        xlab = xlab,
        )
  axis(2)
}

n1 <- 100
n2 <- 10000
a <- 2

par(mfrow = c(1,2))
prop_hist(rexp(n1, rate = a))
prop_hist(rexp(n2, rate = a))
```

Först betraktar vi resultatet av simuleringen för exponentialfördelningen med $a = 2$ (se Fig. 5). De simulerade slumpstalen ser ut att följa en exponentialfördelning: histogrammet är högerskeva och har störst andel observationer nära 0, varefter andelen observationer minskar när värdet ökar. Man kan dessutom observera att den förväntade formen blir tydligare när antalet observationer ökar från $n_1 = 100$ till $n_2 = 10000$.




Figur 5: Andelshistogram för exponentialfördelade slumpstal med $a = 2$ för $n_1 = 100$ respektive $n_2 = 10\,000$ observationer.

```

m <- 10
s <- 2

par(mfrow = c(1,2))
prop_hist(rnorm(n1, mean = m, sd = s))
prop_hist(rnorm(n2, mean = m, sd = s))

```



Figur 6: Andelshistogram för normalfördelade slumpstal med $m = 10$ och $s = 2$ för $n_1 = 100$ respektive $n_2 = 10\,000$ observationer.

För normalfördelningen är histogrammet ungefär symmetriskt kring väntevärdet $m = 10$. De flesta observationerna ligger nära väntevärdet, och andelen observationer minskar ju längre från m värdet ligger, vilket ger den karakteristiska klockformen (se Fig. 6). På samma sätt som för exponentialfördelningen blir den karakteristiska formen tydligare när antalet observationer ökar från $n_1 = 100$ till $n_2 = 10\,000$.

Uppgift 3

I denna uppgift undersöker vi genom simulering om transformationen $V = 1 - e^{-2X}$, där X är exponentialfördelad, ger en likformigt fördelad variabel V .

```

set.seed(19981207)
n <- 1000

```

```


x <- rexp(n, rate = 2)
v <- 1 - exp(-2 * x)

# Plotta x och v bredvid varandra
par(mfrow = c(1, 2))
prop_hist(x, xlab = "X")

attributes <- calculate_attributes(n)

andel_hist(v, attributes$E_Y, attributes$D_Y, xlab = "V")

```



Figur 7: Andelshistogram för exponentialfördelade slumpstal X och den transformerade variabeln $V = 1 - e^{-2X}$, med $n = 1000$ observationer.

Histogrammet för X visar den karakteristiska högerskevheten hos exponentialfördelningen, medan histogrammet för V ser ungefär likformigt ut mellan 0 och 1. För V ligger samtliga observerade andelar inom intervallet $E(Y) \pm 3D(Y)$, vilket ger ytterligare stöd för att V är likformigt fördelad. Resultatet stämmer därmed överens med det teoretiska resultatet.