

Laboration 2

Sannolikhhetsteori I

Emil Erikson och Leo Levenius*

2025-10-10

Förberedelser

Före en laboration, gör följande:

1. **Läs igenom filen “Laborationskrav” på kurshemsidan.**
2. För instruktioner på hur man skapar korrekta tabeller och diagram samt generella tips, läs igenom följande filer på kurshemsidan:
 - “Skapa tabeller från vektorer + text och numrering av tabeller och diagram”
 - “Introduktion till Rstudio, R Markdown, och R”
 - “Exempel R och R Markdown”
 - “Matematiska symboler i R Markdown/LaTeX”
3. Ladda ned laborationsmallen.
4. Under “Tools/Global Options/Code/Saving/Default text encoding”, tryck “Change” och välj “UTF-8”.

*Tidigare versioner av Monir Bounadi, Benjamin Kjelsson, Maria Deijfen, Andreas Nordvall Lagerås, Tom Britton, Jens Malmros, och OE.

Inledning

Syftet med laboration 2 är att undersöka slumpalsgeneratorn i R samt att illustrera de teoretiska resultaten angående fördelning för funktioner av stokastiska variabler med hjälp av simulering. Med att simulera menar vi att generera "slumptal". Simuleringar är oftast mycket användbara i situationer där det är svårt att komma fram till resultaten teoretiskt eller om man vill skaffa sig en intuitiv förståelse för hur saker fungerar. De "slumptal" man får från datorn är egentligen inte slumpmässiga utan genereras med hjälp av en deterministisk algoritm. Oftast är dock algoritmerna så välgjorda att detta inte leder till några problem. I statistik och sannolikhetsteori vill vi oftast att slumptalen ska se ut att ha genererats av någon av de sannolikhetsfördelningar vi arbetar med—i denna laboration kommer vi att simulera från likformig fördelning, normalfördelning och exponentialfördelning.

Uppgift 1: Test av slumpalsgeneratorn i R

Vi ska i denna labb undersöka slumpalsgeneratorn i R, och vi kommer att börja med den kontinuerliga likformiga fördelningen.

Teoretiska uppgifter

Vi delar in intervallet $[0, 1]$ i k lika stora delintervall, som vi kallar för klasser. Sedan genererar vi n observationer från en *kontinuerlig* likformig fördelning på intervallet $[0, 1]$. Antalet av dessa n observationer som hamnar i första intervallet är en slumpvariabel som vi betecknar X_1 . På liknande sätt betecknar vi antalet som hamnar i andra intervallet X_2 , o.s.v. Besvara följande frågor:

1. Ange det första och sista delintervallet på formen $[a, b]$, där a och b är intervallets gränser. *OBS:* Uttryck a och b med k .
2. Vad är längden på var och ett av de k delintervallen?
3. Låt säga att vi genererar ett slumptal från den kontinuerliga likformiga fördelningen på $[0, 1]$.
 - Vad är sannolikheten att detta slumptal hamnar i det första delintervallet?
 - Vad är sannolikheten att detta slumptal *inte* hamnar i det första delintervallet?
 - Vilken sannolikhetsfördelning beskriver sannolikheten att hamna i det första intervallet eller inte? Ange parametern hos fördelningen.
4. Om vi nu som i beskrivningen genererar n sådana slumptal, oberoende av varandra, vad är sannolikheten att j av dessa hamnar i det första delintervallet? D.v.s., för $j = 0, 1, \dots, n$, vad är $\mathbb{P}(X_1 = j)$? Vilken fördelning följer X_1 ? Ange parametrarna hos fördelningen.
5. Har $X_2, \dots, X_k$ samma sannolikhetsfördelning som X_1 ? Är $X_1, X_2, \dots, X_k$ oberoende av varandra? Motivera!
6. Betrakta nu i stället andelen av observationerna som hamnar i första intervallet. Detta är också en slumpvariabel, $Y_1 = X_1/n$. Ange väntevärde, varians och standardavvikelse för Y_1 . *Tips:* Börja med att härleda $E(X_1)$ och $\text{Var}(X_1)$.

Kod-relaterad uppgifter

Vi ska först undersöka slumpalsgeneratorn för kontinuerliga likformiga slumptal. Vi skapar först ett dataset (en vektor `slumptal`) med 100 observationer från en likformig fördelning på intervallet $[0, 1]$.

```

# Först ger vi ett "frö" (seed) till slumpalsgeneratorn genom funktionen set.seed
# Detta gör att vi får exakt samma slumpal varje gång vi kör koden.
set.seed(19690420) # fyll i ditt egna födelsedatum. Om ni jobbar i par, välj den enas.

# För att simulera likformiga slumpal kör vi funktionen runif (random uniform)
slumptal <- runif(100) # runif = random uniform
# Skriv ?runif i Console i RStudio för mer info om denna funktion

```

Vi gör sedan ett histogram över slumpalen på följande sätt.

```

hist(slumptal,
     breaks = seq(from = 0, to = 1, length.out = 10 + 1), # Skapar 10 delintervall.
     main = "Histogram",
     ylab = "Antal",
     xlab = "Värde")

```

Andelar

Hur ska man veta hur stora avvikelser från den förväntade andelen observationer i en viss klass som kan accepteras utan att slumpalsgeneratorn måste anses defekt? Storleksordningen på rimliga avvikelser kan man få fram genom att titta på den teoretiska standardavvikelsen: Man kan visa att avvikelser från den förväntade andelen observationer i en viss klass på mindre än 3 standardavvikelser inte är alltför osannolika. Avvikelser som är större än 3 gånger standardavvikelsen är mycket osannolika och får man detta kan börja misstänka att slumpalsgeneratorn inte fungerar så bra.

Vi ska nu göra histogram över andelen observationer i klasserna (intervallen) och undersöka om de observerade andelarna tycks hålla sig inom felmarginalen (3 standardavvikelser från väntevärdet). Följande funktion skapar ett sådant histogram.

```

# definierar en funktion för att skapa andelsdiagram
prop_hist <- function(x, xlab = "Värde") {
  # x: vektor med slumpal (eller annan data)
  # y: vektor med övre och undre gräns, kan användas för att få med övre röda linjen

  p <- hist(x, plot = FALSE)
  p$counts <- p$counts / sum(p$counts) # Konvertera antal till andelar
  plot(p,
       main = "Andelshistogram",
       ylab = "Andel",
       xlab = xlab
       )
  axis(2)
}

```

Låt säga att vi vet att när vi genererar $n = 100$ slumpal så är väntevärdet och standardavvikelsen för andelen slumpal i något av de 10 intervallen känd. Då kan vi göra ett andelshistogram med linjer som är ± 3 standardavvikelser från väntevärdet genom ett kod-stycke likt det följande.

```

# Använd väntevärde och standardavvikelse för X vid hist(), för Y vid prop_hist()
E <- ... # Väntevärdet, beräkna själv genom de teoretiska uppgifterna
D <- ... # Standardavvikelsen, beräkna själv genom de teoretiska uppgifterna

```

```
prop_hist(slumptal)
abline(a = E, b = 0, col = "grey") # Väntevärdet
abline(a = E + 3 * D, b = 0, col = "red") # Väntevärdet + 3 standardavvikelser
abline(a = E - 3 * D, b = 0, col = "red") # Väntevärdet - 3 standardavvikelser
```

Vi kan nu lätt se om vi har några extrema utfall.

Kod-uppgifter

En uppgift är nu att undersöka dessa plottar för olika värden på n (antal observationer):

1. För ett litet värde av n , ser det ut som en likformig fördelning? Motivera varför genom att hänvisa till de teoretiska resultaten.
2. Vad händer då antalet slumpstal n blir stort? Experimentera gärna med olika stora värden.
3. Jämför andelen observationer i klasserna (intervallerna) med de förväntade andelarna och se om avvikelserna verkar stora (jämfört med väntevärde ± 3 standardavvikelser).
4. Får slumpstalsgeneratoren i R godkänt?

Redovisning av uppgift 1

- Svara på frågorna i teoridelen, inklusive härledning och motivering.
- Svara på och resonera kring de kod-relaterade uppgifterna.
- Skapa **två** andelshistogram som illustrerar era svar: ett digram för ett litet värde på n (t.ex. $n = 100$), och ett diagram för ett (mycket) större värde på n (t.ex. $n = 1000$).
 - Diagrammen **måste** ha numrering samt en beskrivande text under diagrammet. *Tips:* Använd `fig.cap`.

Uppgift 2: Normal- och exponentialfördelade slumpstal

R kan även producera normal- och exponentialfördelade slumpstal. Skriver vi

```
rmnorm(n) # rmnorm = random normal
```

får vi en vektor med n stycken $\mathcal{N}(0, 1)$ -fördelade slumpstal. Skriver vi istället

```
rmnorm(n, mean = m, sd = s)
```

får vi istället en vektor med n stycken $\mathcal{N}(m, s^2)$ -fördelade slumpstal (s är standardavvikelsen).

På liknande sätt kan vi få exponentialfördelade slumpvariabler genom

```
rexp(n, rate = a) # rexp = random exponential
```

Vi skapar alltså en vektor med n stycken exponentialfördelade slumpstal med väntevärde $1/a$. För att få histogram över relativa frekvenser i olika klasser kan vi återigen använda funktionen `prop_hist` som vi definierade ovan.

Vi kan visa två andelshistogram bredvid varandra på följande vis.

```
set.seed(19690420) # fyll i ditt egna födelsedatum. Om ni jobbar i par, välj den enas.  
  
par(mfrow = c(1, 2))  
prop_hist(rexp(n1, rate = a))  
prop_hist(rexp(n2, rate = a))
```

Nu är det er tur att experimentera.

1. Välj själv värden på **m** och **s** för normalfördelningen, och **a** för exponentialfördelningen. Skriv i texten vilka värden ni väljer för de olika parametrarna.
2. Prova att göra andelsplottar för olika värden på n , för att bilda en uppfattning av vad som händer. Alla dessa plottar ska inte tas med i rapporten. Endast två diagram per fördelning ska användas, se “Redovisning av uppgift 2” nedan. *Obs:* Använd samma parametrar för de olika värdena på n .
3. Ser de slumpade vektorerna normal- respektive exponentialfördelade ut? Motivera era svar:
 - Jämför med egenskaperna hos de teoretiska fördelningarna. Vilka egenskaper är utmärkande för normal- respektive exponentialfördelningarna?
 - Vad är det ni jämför med, fördelningsfunktionen eller täthetsfunktionen?
- Kom ihåg att använda funktionen `set.seed` med födelsedatum innan ni använder någon av funktionerna `rexp` eller `rnorm`.

Redovisning av uppgift 2

- Svara på den avslutande frågan (fråga 3) i texten ovan.
- Skapa **två** andelshistogram sida vid sida för både normalfördelade slumpstal.
- Skapa **två** andelshistogram sida vid sida för både exponentialfördelade slumpstal.
 - Diagrammen **måste** ha numrering samt en beskrivande text under diagrammet. *Tips:* Använd `fig.cap`.

Uppgift 3: Fördelning för en funktion av stokastiska variabler

Vi ska nu använda simulerade slumpstal för att få en uppfattning om fördelningen för en funktion av en stokastisk variabel. Exempel 3.48 i boken visar teoretiskt att om X är exponentialfördelad med väntevärde $1/2$ så är $V = 1 - e^{-2X}$ kontinuerligt likformigt fördelad mellan 0 och 1. Vi testar om detta verkar rimligt genom simulering.

```
set.seed(19690420) # fyll i ditt egna födelsedatum. Om ni jobbar i par, välj den enas.

x <- rexp(n, rate = 2) # välj värde för n
v <- 1 - exp(-2 * x)

# Plotta x och v bredvid varandra
par(mfrow = c(1, 2))
prop_hist(x, xlab = "X")
prop_hist(v, xlab = "V")
```

Jämför de två andelshistogrammen. Ser det ut som att påståendet stämmer? D.v.s, leder transformationen av de exponentialfördelade slumpstalen till en likformig fördelning? Motivera! Tänk på vad ni redan gjort i denna labb!

Redovisning av uppgift 3

- Svara på frågan i texten ovan, inklusive motivering med hänvisning till tidigare uppgift(er) i denna laboration.
- Skapa andelshistogrammen med de simulerade observationerna från X respektive transformationen V för era egna val av n .
 - Diagrammen **måste** ha numrering samt en beskrivande text under diagrammet. *Tips:* Använd `fig.cap`.